RESEARCH MEETING PREP · 24 SEP 2026

ניסוי H2 BFS — תדריך לפגישה

מנחים: פרופ׳ רוני שטרן · פרופ׳ רמי פוזיס · 196 שאילתות · 9 אלגוריתמים

פריטי פעולה — סטטוס ביצוע

1. טבלת תוצאות לכל 196 השאילתות

טבלה אינטראקטיבית מלאה — 9 אלגוריתמים, דירוג ה-GT לכל שאילתה, צבעים לפי ביצועים יחסית ל-B1. סינון לפי: RAG נכשל, H1 השתפר, H1 הורע.

טאב: "All 196 Queries" בדוח

2. הוספת מסמכי ייחוס שאינם ה-GT

ניתוח חדש: שורות בטבלת ה-Deep Dives צבועות לפי ציון LLM. פאנל חדש "Top-1 Soft Retrieval" מציג איזה מסמך כל אלגוריתם בחר ראשון ומה הציון שלו. בטאב Summary: ממוצע 16 מסמכים non-GT עם LLM=1.0 לכל שאילתה.

טאב: "Deep Dives" (פאנלים חדשים) + "Summary" (קטע הקשר רך)

3. שלושה מקרי עומק לדוגמה

Q118 (B2 מוצא GT במקום 68), Q37 (H3 מצליח רכות — מחזיר LLM=1.0 שאינו GT), Q119 (B2 במקום 38). כל אחד: עלות לפי אלגוריתם, איכות soft retrieval, וטבלה עם 25 מסמכים צבועים לפי LLM.

טאב: "Deep Dives"

4. בדיקות שפיות (Sanity Checks)

4 בדיקות: B1=RAG, H1→B1 כש-H2≡B1 כש-α→1, 0 (0 מתוך 196 הבדלים), H3 קורס.

טאב: "Sanity Checks"

מספרים לדעת בעל פה

B1 TOP-1 (ברייזליין)	H1 A=0.93 TOP-1	H2 שונה מ-B1
70.4%	**71.4%**	**0 / 196**
ממוצע דירוג 3.29 — הטוב ביותר	+1pp על B1, ממוצע 3.35	זהה לחלוטין — ה-tiebreaker לא מופעל

H3 K=10 TOP-1	B2 DIST(C) TOP-1	NON-GT עם LLM=1.0
17.9%	**14.8%**	**~16**
−52.5pp מ-B1 — קריסת צנטרואיד	הגרוע ביותר — דירוג לפי צנטרואיד בלבד	ממוצע לשאילתה. 29 מסמכים ב-≥0.8

אלגוריתם	Top-1 %	Top-3 %	Top-10 %	ממוצע דירוג
B1 dist(Q)	**70.4**	**83.2**	**91.8**	**3.29**
H1 α=.93	71.4	82.7	90.8	3.35
H1 α=.85	70.9	82.7	90.8	3.40
H1 α=.70	67.9	79.6	89.8	3.71
H2 lex	70.4	83.2	91.8	3.29
H3 k=10	17.9	43.9	91.8	5.05
H3 k=50	14.8	36.2	63.3	9.55
B2 dist(C)	14.8	36.2	62.8	9.87

H3 k=200 ≈ B2 — מתכנס לדירוג צנטרואיד בלבד בk גדול • משולש: ∠GT≈70.6°, ∠C≈70.8°, Q≈45.7° • ROC-AUC(LLM, d(GT)) = 0.9974

שאלות צפויות — תשובות חזקות

Q1 למה H2 נותן תוצאות זהות לחלוטין ל-B1?

כי מרחקי קוסינוס ב**מרחב 768 ממדים** עם **bit floats-64** כמעט ולא יוצרים שוויון מדויק. H2 ממיין לפי dist(Q) ומשתמש ב-dist(C) רק לשבירת שוויון — אבל ב-**196/196** שאילתות לא קיים שוויון כלל. ה-tiebreaker אף פעם לא מופעל. **זו בעצם בדיקת שפיות מצוינת**: היא מאשרת שה-pipeline עובד נכון ושהנחת היסוד של H2 (שקיימות תיקו) שגויה לנתונים אלה.

Q2 למה הצנטרואיד מזיק? (B2 ו-H3 שניהם קורסים)

גיאומטריית המשולש Q-C-GT מסבירה זאת. הצנטרואיד C **אינו נמצא על הציר Q→GT**. הזווית בין Q לבין C היא ∠Q≈45.7°, אך הזווית בין Q לבין GT היא ∠C — C≈70.8° ו-GT מתפצלים ב-46° כפי שנראה מ-Q. דירוג לפי dist(C) בוחר מסמכים שהם "מרכזיים" לקבוצת הפול בממוצע, לא מסמכים שעונים על השאילתה הספציפית. **H3 k=10** מגביל ל-10 המסמכים הקרובים ל-Q ואז ממיין לפי dist(C) — מה שמבטל בפועל את האות של Q בתוך הרשימה הקצרה.

Q3 האם +1pp של H1 משמעותי סטטיסטית?

באופן כן — זה שולי. **+1.0pp** ב-Top-1 (71.4% מול 70.4%) עם N=196 כנראה לא מובהק סטטיסטית. H1 גם **מאבד מעט ב-Top-10** (90.8% מול 91.8%). ההטבה קטנה ולא עקבית בין המדדים. הממצא המרכזי הוא שH1 לא יכול לשפר משמעותית את B1 כיוון שהצנטרואיד אינו אות אמין לרוב השאילתות.

Q4 מה מראה ניתוח "soft retrieval" (מסמכי ייחוס שאינם GT)?

לכל שאילתה, הפול מכיל בממוצע **16 מסמכים non-GT עם ציון LLM=1.0** ו-29 עם ציון ≥0.8. כלומר, המדד הבינארי "מצא את ה-GT?" הוא מחמיר. שלושת מקרי העומק מראים שני סוגי כשל שונים: ב-Q118, המסמך הראשון שH3 בוחר מקבל LLM=0.2 (לא

רלוונטי — הצנטרואיד הוביל לכיוון הלא נכון). ב-Q37, המסמך הראשון של H3 מקבל LLM=1.0 (תשובה חלופית תקפה — H3 הצליח רכות למרות שלא מצא את ה-GT הרשמי).

Q5 מה בדיוק הצנטרואיד? כיצד חושב?

הצנטרואיד C לכל שאילתה הוא **ממוצע וקטורי (mean)** של ה-embeddings של מסמכי המועמדים שנאחזו בפאס הראשוני של RAG. הוא מייצג את "מרכז הכובד" של קבוצת הפול. מבנה המשולש Q-C-GT הכמעט-אוניברסלי (שווה-שוקיים, זוויות קבועות כמעט ב-196 שאילתות) מראה שהצנטרואיד עקבי גיאומטרית — אך עקביות גיאומטרית לא אומרת שימושיות לאחזור.

Q6 למה Top-10 של H3 k=10 זהה ל-B1 (91.8%)?

כי H3 רק ממיין מחדש בתוך ה-10 הקרובים ל-Q — הוא לא מסיר מסמכים מהרשימה. אם ה-GT היה בתוך ה-Top-10 של dist(Q) (91.8% מהשאילתות), הוא עדיין נשאר שם גם אחרי ממיון של H3. **זו תצפית מנומקת, לא מקרה** — היא מאשרת שהקוד תקין.

לטפל בזהירות

! "למה לא בדקת ערכי α מתחת ל-0.7?"

תשובה טובה: ב-α=0.70 משקל הצנטרואיד (0.30) כבר גורם לירידה של **−2.5pp**. מתחת ל-0.7 הצנטרואיד שולט יותר ויותר והביצועים מתכנסים ל(14.8%) B2. המגמה מונוטונית וברורה — בדיקות נוספות לא יוסיפו תובנות חדשות. **הצג זאת כנקודת עצירה מכוונת, לא כחסר.**

! "16 מסמכים non-GT עם LLM=1.0 — האם זה אומר שה-GT labels שלך רועשים?"

לא — ה-GT הוא התשובה המסומנת מהדאטאסט. מסמכים מרובים יכולים להוות תשובות תקפות לאותה שאלה (במיוחד בשאלות ביו-רפואיות). 16 המסמכים האחרים עם LLM=1.0 הם רלוונטיים באמת אך לא נבחרו כ-GT. **זו תכונה של הדאטאסט, לא בעיית תיוג.** כן מציע שהערכה עתידית תשקול מדדים רכים (MRR על מסמכים רלוונטיים, לא רק GT recall).

? "מה הצעד הבא — מה זה מציע לעבודה עתידית?"

הצנטרואיד של הפול הגולמי אינו אות אמין. מה שעשוי לעזור: **(א)** צנטרואיד מסונן-LLM — ממצע רק מסמכים בעלי ציון גבוה במקום כל הפול; **(ב)** שיפור איטרטיבי — שימוש במסמך המקורב ביותר לעדכון וקטור השאילתה; **(ג)** α מותאם לשאילתה — המשקל האופטימלי תלוי בשאילתה (חלק מרוויחות מ-C, רוב לא). **היה קונקרטי, ציין לפחות אחת מאפשרויות אלה אם נשאל.**

? "מספרי Top-10 שלך — B1 ו-H3 k=10 שניהם 91.8%. זה מקרי?"

לא, זה מבני. H3 k=10 מגביל את קבוצת המועמדים לאילו ה-10 הקרובים ל-dist(Q), אז ה-Top-10 שלו *מייב* להיות שווה ל-Top-10 של B1: אם ה-GT נמצא ב-Top-10 של B1 (91.8% מהשאילתות), הוא עדיין נמצא בקלט של H3 לפי הגדרה. **זו תצפית מנומקת, לא מקרה — מאשרת שהקוד נכון.**

נרטיב מרכזי להוביל איתו: כל ארבעת פריטי הפגישה הושלמו. הממצא המרכזי הוא שהיוריסטיקות מבוססות-צנטרואיד — כ-tiebreaker (H2), כמשקל היברידי (H1), או כ-re-ranker (H3) — לא מצליחות לשפר משמעותית את אחזור dist(Q) הרגיל. H2 לא מוסיף כלום. H1 מוסיף לכל היותר +1pp. H3 מזיק באופן פעיל. הניתוח הגיאומטרי מסביר מדוע: הצנטרואיד של הפול הוא עוגן יציב במרחב ה-embedding, אך הוא אינו מצביע לכיוון התשובה הספציפית של השאילתה.