ניתוח קבוצות גיאומטריות: סיכום ניסוי

Bar Damri | אוגוסט 2026

סקריפט: `experiments/global_correlation/analyze_groups.py`

נתונים: אותו pool ו-DB של ניסוי 2 (199 שאילתות, 25M PubMed, 1,000,174 זוגות)

שאלת הניסוי

לאחר שהוכחנו שקיים קורלציה שלילית בין ציון ה-LLM למרחק מ-GT, רצינו להבין את **המבנה הגיאומטרי** של הנתונים בצורה מעמיקה יותר. הגדרנו שלוש קבוצות גיאומטריות לכל שאילתה ובדקנו את החפיפה ביניהן.

הגדרת הקבוצות

קבוצה	הגדרה	מחשב לפי
G1	כל המסמכים שנמצאים **במעגל סביב השאילתה** ברדיוס dist(query, GT)	re-embedding עם `all-mpnet-base-v2`
G2	כל המסמכים שנמצאים **במעגל סביב הצנטרואיד של G3** ברדיוס dist(centroid, GT)	re-embedding + centroid
G3	כל המסמכים שקיבלו **ציון מושלם (1.0) מה-LLM**	`experiment_results.db`

פרשנות:

- G1 = תחום ה"אחריות" של הריטריבר: מסמכים שהריטריבר "יכול" לאחזר לפני ה-GT
- G3 = "הדעה" של ה-LLM: מסמכים שהוא מגדיר כרלוונטיים לחלוטין
- G2 = פילטר גיאומטרי על G3: "ליבת" G3 לפי מרחק מהצנטרואיד

שיטת הניתוח

1. **Re-embedding:** הטמעת 199 שאילתות ו-39,507 מסמכי pool מחדש בעזרת `sentence-transformers/all-mpnet-base-v2` (אותו מודל שנעשה בניסוי המקורי)

2. **חישוב G1:** dist(doc, query) ≤ dist(query, GT): cosine distance

3. **חישוב G3:** llm_score = 1.0 מ-DB

4. **חישוב G2:** centroid = ממוצע ממושקל של וקטורי G3; radius = dist(centroid, GT)

5. **חפיפות:** Jaccard + intersection ביחס לכל קבוצה, לכל שאילתה בנפרד

6. **פלטים:** 196 CSVs פר-שאילתה + global_aggregates.csv + master_summary.csv

---

תוצאות

גדלי קבוצות (196 שאילתות)

קבוצה	ממוצע	חציון	מינימום	מקסימום
G1	3.1	**1**	0	26
G2	9.7	**6**	0	68
G3	17.1	**18**	3	38

GT-membership

קבוצה	כולל	rag_ok (n=138)	rag_failed (n=58)
G1	**84.7%**	89.1%	74.1%
G2	**85.2%**	88.4%	77.6%
G3	**94.9%**	99.3%	84.5%
G1 ∩ G2 ∩ G3	**76.0%**	79.0%	69.0%

חפיפות בין קבוצות

G1 ∩ G2:

מדד	כולל	rag_ok	rag_failed				
\	\G1∩G2\	\ /	\G1		**85.2%**	89.4%	76.3%
\	\G1∩G2\	\ /	\G2		35.4%	29.4%	49.3%
Jaccard	0.326	0.290	0.411				

G1 ∩ G3:

מדד	כולל	rag_ok	rag_failed				
\	\G1∩G3\	\ /	\G1		**93.2%**	**99.2%**	80.6%
\	\G1∩G3\	\ /	\G3		13.8%	7.1%	29.8%
Jaccard	0.125	0.071	0.252				

G2 ∩ G3:

מדד	כולל	rag_ok	rag_failed				
\	\G2∩G3\	\ /	\G2		**83.5%**	84.1%	81.9%
\	\G2∩G3\	\ /	\G3		41.6%	36.4%	53.8%
Jaccard	0.336	0.291	0.442				

G3 ∩ G2 ∩ G1:

\	∩\	\ /	\G1\		\	∩\	\ /	\G2\		\	∩\	\ /	\G3\		Jaccard
81.2%	33.0%	12.0%	0.100												

כש-G1 מכיל בדיוק מסמך אחד (126/196 שאילתות = 64%):

- ה-GT הוא אותו מסמך ב-**97.6%** מהמקרים

מרחקים: ממצא מרכזי

מרחק	ממוצע	חציון
dist(query, GT)	0.173	0.154
dist(centroid_G3, GT)	**0.097**	**0.086**
שיפור יחסי	**43.6%**	**44.3%**

הצנטרואיד של G3 קרוב ל-GT ב-44% יותר מהשאילתה המקורית.

הפרש המרחקים: ניתוח מפורט

הפרש = dist(query, GT) − dist(centroid, GT): ערך חיובי = הצנטרואיד טוב יותר.

מדד	כולל (196)	rag_ok (138)	rag_failed (58)
צנטרואיד קרוב יותר	**92.3% = 181/196**	89.9% = 124/138	98.3% = 57/58
ממוצע הפרש	**0.076**	0.061	0.110
חציון הפרש	**0.065**	0.053	0.097
סטיית תקן	0.066	0.056	0.074
מינימום (הכי גרוע)	0.173−	0.173−	0.020−
מקסימום (הכי טוב)	0.408+	0.243+	0.408+

פרשנות:

- ב-**92.3%** מהשאילתות הצנטרואיד קרוב יותר ל-GT: לא רק בממוצע, אלא בכל שאילתה בנפרד.
- ב-**rag_failed** השיפור חזק פי 1.8 (ממוצע 0.110 לעומת 0.061 ב-rag_ok): המקרים שהריטריבר נכשל בהם נהנים יותר מהצנטרואיד.
- ב-**7.7%** מהשאילתות (15 מקרים) הצנטרואיד **מרחיק** מה-GT (ערך שלילי עד −0.173): ייתכן כי G3 מכיל מסמכים "שכנים" שמושכים לכיוון לא נכון.

ניתוח חיתוכים: מה כל קבוצה מוסיפה ייחודית

הסכמה בין Retriever ל-LLM

כשה-retriever **מצליח** (rag_ok, n=138): 99.2% מ-G1 נמצא גם ב-G3: הסכמה כמעט מוחלטת.

כשה-retriever **נכשל** (rag_failed, n=58): רק 50.0% מ-G1 נמצא ב-G3: כשהריטריבר אובד, הוא מוצא מסמכים גיאומטרית-קרובים שה-LLM דוחה.

מסקנה: G1∩G3 הוא אינדיקטור חזק: כשהריטריבר וה-LLM מסכימים, כמעט תמיד זה ה-GT.

תרומה ייחודית של כל קבוצה (GT coverage)

מקרה	שאילתות	אחוז
GT ב-G1, לא ב-G3 (retriever מצא, LLM פספס)	1/196	**0.5%**
GT ב-G3, לא ב-G1 (LLM מציל מה שריטריבר פספס)	21/196	**10.7%**
GT ב-G2, לא ב-G1 (G2 מציל מעבר לG1)	17/196	**8.7%**

ה-LLM הוא superset כמעט מושלם של הריטריבר: מקרה אחד בלבד (query 29) שבו הריטריבר מצא והLLM פספס.

G2 מסנן רעש אמיתי מ-G3

G3 מכיל בממוצע **10.1 מסמכים** שG2 מוציא החוצה: מסמכים שה-LLM אוהב אבל גיאומטרית רחוקים מהצנטרואיד. G2 מסנן את ה-noise ומשאיר 6 מסמכים ממוקדים.

כיסוי union: ערך השילוב

שילוב	GT בפנים	גודל חציוני
G1 בלבד	84.7% (166/196)	1
G1 ∪ G2	**93.4% (183/196)**	~7
G1 ∪ G2 ∪ G3	**95.4% (187/196)**	~18

G1∪G2 מספק recall 93.4% עם גודל סביר: פשרה אופטימלית בין recall לדיוק.

ניתוח מורחב: סטטיסטיקות נוספות

התפלגות גדלי G1

G1	שאילתות	%
0 מסמכים	15	7.7%
1 מסמך	126	64.3%
2 מסמכים	17	8.7%
3–5 מסמכים	15	7.7%
יותר מ-5	23	11.7%

ב-72% מהשאילתות G1 מכילה 0 או 1 מסמכים: ממוקדת מאוד או ריקה לחלוטין.

התפלגות גדלי G3

G3	שאילתות	%
3–10 (קטנה)	37	18.9%
11–20 (בינונית)	104	53.1%
21–38 (גדולה)	55	28.1%

כש-G1 ריקה (15 שאילתות = 7.7%)

בכל 15 המקרים GT .rag_failed=0 נמצא ב-G3 ב-**100%** מהמקרים וב-G2 ב-80%: ה-LLM מפצה לחלוטין על היעדר G1.

מתי הצנטרואיד מזיק (15 שאילתות = 7.7%)

שאילתות שהשאילתה כבר **קרובה** ל-GT (dist ממוצע 0.127 לעומת 0.173 בשאר). כשהשאילתה קרובה, הצנטרואיד מושך לאזור רחב יותר. הנזק הממוצע קטן (0.025), ו-14 מתוך 15 הם rag_ok.

מה גורם לצנטרואיד להשתפר יותר

הגורם החזק ביותר: מרחק השאילתה מה-GT ($r=0.720$, $p<10^{-32}$). ככל שהשאילתה רחוקה יותר: הצנטרואיד עוזר יותר.

גורם	קורלציה עם שיפור

dist(query, GT)	r = 0.720
גודל G2	r = −0.263
גודל G1	r = 0.206
גודל G3	r = −0.015 (לא מובהק)

G3 גדולה יותר = צנטרואיד טוב יותר

גודל G3	שיפור ממוצע	צנטרואיד קרוב יותר
קטנה (3–10)	33.9%	83.8%
בינונית (11–20)	39.8%	93.3%
גדולה (21–38)	45.9%	96.4%

התפלגות השיפור (כל 196 שאילתות)

שיפור	שאילתות	%
שלילי	15	7.7%
0–20%	19	9.7%
20–40%	48	24.5%
40–60%	75	38.3%
מעל 60%	39	19.9%

כשכל שלוש הקבוצות מפספסות GT

9 שאילתות בלבד (4.6%): ב-100% מהן rag_failed=1. כשהריטריבר מצליח, לפחות קבוצה אחת תמיד מוצאת את ה-GT.

אות הביטחון הגבוה ביותר

כש-G1 מכילה בדיוק מסמך אחד **והוא גם ב-G3**: ב-97.6% מהמקרים זה ה-GT. זה קורה ב-125/196 שאילתות (63.8%).

תפקיד G2

G2 אינה מוצאת GT חדש שלא קיים ב-G3 (קורה פעם אחת בלבד = 0.5%). תפקידה הוא **לסנן את G3** ולהשאיר את הגרעין הממוקד.

מסקנות

1. G1: כלי הריטריבר: מדויק אבל לא מלא

כאשר הריטריבר מצליח (rag_ok), G1 מכיל **מסמך אחד בדיוק** ב-89% מהמקרים, ואותו מסמך הוא ה-GT ב-100% מהמקרים. G1 בקבוצת rag_ok היא **מצביע מדויק**: הריטריבר מרוכז בדיוק סביב ה-GT.

בקבוצת rag_failed, G1 מתרחבת (חציון 4, ממוצע 8.5) וה-GT אינו בה ב-26% מהמקרים: הריטריבר "מבולבל".

2. G3: כלי ה-LLM: recall גבוה, precision אפסי

G3 מכיל את ה-GT ב-94.9% מהמקרים: זו כמות ה-recall הגבוהה. אבל: **ממוצע 16.1 מסמכים לא-GT מקבלים ציון 1.0 לצד ה-GT**. ה-LLM אינו מסוגל להפריד בין G3-members: כולם 1.0, וה-Score Quantization מונע tiebreaking. G3 היא "דלי גדול" שמכיל את ה-GT אבל לא יכול לבודד אותו.

3. G2: סינתזה: מנצל את שניהם

G2 מסנן את ה-G3 גיאומטרית לפי מרחק מהצנטרואיד:

- שומרת GT ב-85.2% (דומה ל-G1)
- גדולה מ-G1 (חציון 6 לעומת 1): coverage טוב יותר
- מכילה 84% מ-G3: דוחה 16% שהם noise

4. הממצא הגיאומטרי המרכזי

הצנטרואיד של מסמכי (LLM-scored perfect) G3 **קרוב ל-GT ב-44% יותר** מהשאילתה המקורית. זה אומר:

> **פעולה אחת של "מי הכי רלוונטי לפי LLM → מרכז המסה שלהם" מקדמת את נקודת הייחוס ב-44% לכיוון ה-GT.**

זוהי ההוכחה הגיאומטרית הישירה לעיקרון הטריליטרציה: הצנטרואיד הוא נקודת פתיחה טובה יותר לאיטרציה הבאה מהשאילתה עצמה.

פלטים

```
analysis/csv/group_analysis/
├── master_summary.csv        : שורה לכל שאילתה (196 שורות)
├── global_aggregates.csv     : mean/median/std/min/max לכל מדד
└── per_query/
    ├── query_001.csv
    ├── query_002.csv
    ...
    └── query_199.csv          (196 שאילתות לא כללו 3 ,קבצים GT embedding)
```

schema: master_summary.csv

עמודה	תיאור
query_idx, gt_id, rag_failed	מזהים
dist_query_to_gt	dist(query, GT): cosine
dist_centroid_to_gt	dist(centroid_G3, GT): cosine
n_pool, n_g1, n_g2, n_g3	גדלי קבוצות
n_g1_g2, n_g1_g3, n_g2_g3, n_g1_g2_g3	גדלי חיתוכים
jaccard_g1_g2, jaccard_g1_g3, jaccard_g2_g3, jaccard_g1_g2_g3	Jaccard
gt_in_g1, gt_in_g2, gt_in_g3, gt_in_all	האם GT נמצא בקבוצה (0/1)
g1_doc_ids, g2_doc_ids, g3_doc_ids	רשימת PMIDs מופרדים ב-"| "

schema: per_query CSVs

עמודה	תיאור
doc_id	PMID
llm_score	ציון ה-LLM
dist_to_gt_db / dist_to_gt_reembed	מרחק מ-GT (DB + re-embed)

dist_to_query	dist(doc, query): cosine
dist_to_centroid	dist(doc, centroid_G3): cosine
is_gt	0/1
in_g1, in_g2, in_g3	שייכות (0/1)
in_g1_and_g2, in_g1_and_g3, in_g2_and_g3, in_all	חיתוכים (0/1)